



RIVER PLATE



UCAM
UNIVERSIDAD
CATÓLICA DE MURCIA

Automatización y Gestión de Información con Python y MySQL

Parte 2. Procesamiento y Análisis Exploratorio

Guillermo Román

Abril de 2026

Limpieza de Datos

Una vez extraídos los textos crudos de los archivos CVS y PDF, se procedió a realizar el “*Data Cleasing*”, con el fin de enviar el almacenamiento de “texto basura” en las estructuras de datos posteriores: Listas, Diccionarios y DataFrames. Dependiendo del tipo de fuente de datos, los archivos crudos se limpiaron de una forma en particular:

- **Archivos .CVS:** El texto extraído se almacenó en un DataFrame de Pandas. Y se utilizó la función de *isnull()*, para determinar la existencia de valores nulos (NaN). Como los valores nulos estaban en el campo “*Estadio*” se llenó con el valor “DESCONOCIDO”

```
#Se copia el dataframe, para realizar las transformaciones necesarias sin afectar el original.
df_Resultados = df_Resultados_TA25_GrupoB.copy()

#Se Rellenan los valores nulos de la columna "Estadio" con "DESCONOCIDO"
df_Resultados['Estadio'] = df_Resultados['Estadio'].fillna("DESCONOCIDO")

#Se verifica que no existan valores nulos en el dataframe después de la transformación.
print("Valores Nulos por Columna:")
Valores_Nulos= df_Resultados.isnull().sum()
print(Valores_Nulos)

#Se muestran las primeras filas del dataset, para verificar su contenido.
display(df_Resultados.head())
```

Valores Nulos por Columna:

Jornada	0
Fecha/hora	0
Estadio	0
Partido	0
Resultado	0
Estado	0

dtype: int64

Al observarse que los tipos de datos del campo “*Fecha/Hora*” estaban almacenados como “String”, se procedió a hacer el ajuste correspondiente.

```
#Verificar tipo de Datos en Campo Fecha/hora
print("Tipo de Datos en Campo fecha/hora: ", df_Resultados['Fecha/hora'].dtype)

#Convertir Campo Fecha/hora de String a DateTime.
df_Resultados['Fecha/hora'] = pd.to_datetime(df_Resultados['Fecha/hora'], format='%d.%m.%Y %H:%M')
print("Tipo de Datos en Campo fecha/hora, luego de la conversión: ", df_Resultados['Fecha/hora'].dtype)

#Se muestran las primeras filas del dataset, para verificar su contenido.
display(df_Resultados.head())

#Información general del dataset, para verificar las correcciones realizadas.
df_Resultados.info()
```

Tipo de Datos en Campo fecha/hora: str
Tipo de Datos en Campo fecha/hora, luego de la conversión: datetime64[us]

	Jornada	Fecha/hora	Estadio	Partido	Resultado	Estado
0	1	2025-04-12 09:30:00	LICEO LOS OLIVOS	ACADEMIA M.F.C - CORE SPORT	0:4	JUGADO
1	1	2025-04-10 15:30:00	DESCONOCIDO	ACADEMIA DEPORTIVA EMANUEL - ESCUELA DE FUTBOL...	3:3	JUGADO
2	1	2025-04-11 16:00:00	"LOS OLIVOS" PTO. ORDAZ	LOS OLIVOS - ACADEMIA SUR AEROPUERTO FC	0:5	JUGADO
3	2	2025-03-21 15:00:00	CANCHA VILLA BETANIA	S LUGO FC - ACADEMIA M.F.C	1:2	JUGADO
4	2	2025-03-22 14:00:00	CANCHA EL CAMPITO-CORE 8	CORE SPORT - ACADEMIA DEPORTIVA EMANUEL	3:0*	JUGADO

- **Archivos .PDF:** La metodología de extracción del texto fue más compleja, debido a que los archivos PDF son semi estructurados. Se utilizó la librería “*pdfplumber*”, y para que el texto crudo tuviera sentido, se dividió el proceso en fases:

- **Detección de Patrones (Regex):** Implementación de expresiones regulares para capturar correctamente patrones de nombres, dorsales y números.

```
#Capturar la liga
match_liga = re.search(r'LIGA\s+(.*?)\s+FÚTBOL CAMPO', texto)
if match_liga:
    resultado['liga'] = match_liga.group(1)
```

```
# Patrón de descubrimiento: (Numero Lista) (Dorsal) (Nombre) (T/S) (A/C opcional)
patron_descubrimiento = r"(\d+)\s+(\d+)?\s+([A-Za-z\ñÑáéíóúÁÉÍÓÚ]+\s+([TtSs]))?(:\s+([AaCc][\d]*))?"
```

- **Anclaje Geográfico:** Uso de coordenadas para seccionar las páginas del Informe COMET en dos "cajas": *Local* y *Visitante*, y así extraer correctamente el texto deseado.

```
ancho_mitad = pag_goles.width / 2
cajas = {
    "LOCAL": (0, y_inicio, ancho_mitad, y_fin),
    "VISITANTE": (ancho_mitad, y_inicio, pag_goles.width, y_fin)
}
```

- **Normalización de Nombres:** Implementación de un algoritmo de limpieza, que elimina ruidos (como textos huérfanos o sin sentido) y reestructura nombres largos a un formato estándar de: 2 Apellidos y 2 Nombres.

```
# Filtramos para asegurar que solo recogemos letras (evitando basura numérica)
texto_antes = re.sub(r'^[A-Za-z\ñÑáéíóúÁÉÍÓÚ\s]', '', texto_antes).strip()
texto_despues = re.sub(r'^[A-Za-z\ñÑáéíóúÁÉÍÓÚ\s]', '', texto_despues).strip()
```

```
# Procesar el nombre (estricto: 4 palabras máximo)
nombre_completo = partes[2].split()
if len(nombre_completo) >= 4:
    nombre_final = " ".join(nombre_completo[:4])
else:
    continue # Se ignora por formato incompleto
```

Transformación y Enriquecimiento

El objetivo era obtener los datos del desempeño de los goleadores SUB-15 de ACADEMIA M.F.C durante el torneo Apertura 2025, para ello, se procedió a utilizar la función “*procesar_goleadores_torneo_pdfs(carpetas)*”, donde se extrajo los datos específicos de los jugadores con goles anotados, de todas las planillas COMET ya generadas. Sin embargo, para tener la información solicitada, se tuvo que aplicar otras funciones y filtros sobre el DataFrame de Goleadores.

```
# Crear un ranking avanzado desglosando el tipo de anotación
df_goleadores_integral = df_goleadores_torneo_apertura.groupby(['jugador']).agg(
    equipo=('equipo', 'first'),
    total_goles=('jugador', 'count'),
    goles_jugada=('tipo_gol', lambda x: (x == 'JUGADA').sum()),
    goles_penal=('tipo_gol', lambda x: (x == 'PEN').sum()),
    goles_autogol=('tipo_gol', lambda x: (x == 'AG').sum())
).reset_index()

# Ordenar y ajustar índice
df_goleadores_integral = df_goleadores_integral.sort_values(by='total_goles', ascending=False).reset_index(drop=True)
df_goleadores_integral.index = df_goleadores_integral.index + 1

# Convertir los strings en mayúsculas, para estandarizar la información
df_goleadores_integral['jugador'] = df_goleadores_integral['jugador'].str.upper()

# Mostrar el ranking de goleadores detallado, con el total de goles y el desglose por tipo de anotación.
print("\n📊 TABLA DE GOLEADORES SUB-15 - TORNEO APERTURA 2025 - GRUPO B")
display(df_goleadores_integral)
```

📊 TABLA DE GOLEADORES SUB-15 - TORNEO APERTURA 2025 - GRUPO B

	jugador	equipo	total_goles	goles_jugada	goles_penal	goles_autogol
1	ADEDIGBA ZAPATA EMMANUEL ADEREMI	ACADEMIA M.F.C	7	7	0	0
2	GUTIERREZ BOLIVAR MATHIAS EDUARDO	ACADEMIA M.F.C	6	6	0	0
3	VALDEZ ROCA GABRIEL ALEXANDER	S LUGO FC	3	3	0	0
4	MARCANO ALCALA NELSON JAVIER	ACADEMIA M.F.C	2	2	0	0
5	GONZALEZ MARCANO GUILLERMO ALEJANDRO	ACADEMIA SUR AEROPUERTO FC	2	2	0	0

Análisis Exploratorio

Una vez filtrados los datos, para tener solo la información asociada a la Academia M.F.C, se reveló que la efectividad de la cantera no es lineal. Se detectó, por ejemplo, que un goleador mantiene una cuota alta cuando juego de local, pero su participación decae en contextos de visitante, y con otros goleadores ocurre exactamente lo contrario, lo que sugiere una *oportunidad de intervención táctica o de acompañamiento psicológico*.

```
# --- VISTA FILTRADA ACADEMIA MFC CON SUS PROPIOS TOTALES ---
df_mfc = df_goleadores_detallado[df_goleadores_detallado['equipo'].str.contains('ACADEMIA M.F.C', case=False, na=False)].copy()

if not df_mfc.empty:
    sumas_mfc = df_mfc[columns_numericas].sum()
    fila_total_mfc = pd.Series(data=sumas_mfc, index=columns_numericas)
    fila_total_mfc['jugador'] = 'TOTAL CANTERA MFC'
    fila_total_mfc['equipo'] = 'ACADEMIA M.F.C'

    df_mfc_final = pd.concat([df_mfc, fila_total_mfc.to_frame().T], ignore_index=True)
    df_mfc_final.index = df_mfc_final.index + 1

    print("\n📊 DESEMPEÑO INDIVIDUAL: GOLEADORES SUB-15 CANTERA ACADEMIA MFC - TORNEO APERTURA 2025 - GRUPO B")
    display(df_mfc_final)
```

📊 DESEMPEÑO INDIVIDUAL: GOLEADORES SUB-15 CANTERA ACADEMIA MFC - TORNEO APERTURA 2025 - GRUPO B

	jugador	equipo	total_goles	goles_local	goles_visitante	jugada	penal	autogol
1	ADEDIGBA ZAPATA EMMANUEL ADEREMI	ACADEMIA M.F.C	7	5	2	7	0	0
2	GUTIERREZ BOLIVAR MATHIAS EDUARDO	ACADEMIA M.F.C	6	2	4	6	0	0
3	MARCANO ALCALA NELSON JAVIER	ACADEMIA M.F.C	2	0	2	2	0	0
4	DIAZ VILLEGAS SAMUEL ALEJANDRO	ACADEMIA M.F.C	1	1	0	1	0	0
5	MARCANO CAMACHO JUAN MARCOS	ACADEMIA M.F.C	1	1	0	0	1	0
6	RINCONES RUIZ GUILLERMO ALEXANDER	ACADEMIA M.F.C	1	1	0	1	0	0
7	TOTAL CANTERA MFC	ACADEMIA M.F.C	18	10	8	17	1	0

Observando las estadísticas descriptivas, con la función `.describe()`, se pueden extraer hallazgos muy valiosos. Las cifras cuentan la historia de un equipo que tiene una jerarquía ofensiva muy marcada y una identidad de juego clara.

--- Estadísticas Descriptivas del DataFrame de GOLEADORES SUB-15 - CANTERA ACADEMIA MFC

	total_goles	goles_local	goles_visitante	jugada	penal	autogol
count	6.00000	6.000000	6.000000	6.000000	6.000000	6.0
mean	3.00000	1.666667	1.333333	2.833333	0.166667	0.0
std	2.75681	1.751190	1.632993	2.926887	0.408248	0.0
min	1.00000	0.000000	0.000000	0.000000	0.000000	0.0
25%	1.00000	1.000000	0.000000	1.000000	0.000000	0.0
50%	1.50000	1.000000	1.000000	1.500000	0.000000	0.0
75%	5.00000	1.750000	2.000000	5.000000	0.000000	0.0
max	7.00000	5.000000	4.000000	7.000000	1.000000	0.0

Observaciones clave:

- **Polarización.** Existe una brecha significativa entre la producción promedio y los líderes de goleo.
 - **Volumen:** Hay un universo de **6 goleadores** registrados en el periodo.
 - **Desigualdad:** Mientras que la **mediana (50%)** es de apenas **1.5 goles**, el valor **máximo es de 7**. Esto indica que el peso ofensivo recae fuertemente en 1 o 2 jugadores (Enmanuel Adedigba y Mathías Gutiérrez).
 - **Insight:** El equipo es altamente dependiente de sus finalizadores principales. Si el rival logra anular al jugador con el récord de 7 goles, la probabilidad de anotar cae drásticamente.
- **ADN de Juego: Goles de Jugada.** El equipo no depende de autogoles del rival, ni de balones detenidos para marcar.
 - **Dominio de Jugada:** El promedio de goles de jugada (**2.83**) es casi idéntico al promedio de goles totales (**3.0**).
 - **Penales:** La incidencia es mínima (*media de 0.16*), con un máximo de solo **1 gol de penal** entre todos los jugadores.
 - **Insight:** Esto habla muy bien del proceso formativo y la capacidad asociativa de la Sub-15. El equipo genera sus propias ocasiones a través del sistema táctico, lo cual es ideal en etapas de desarrollo.
- **Factor de Localía vs. Visitante.** El rendimiento es equilibrado, lo que sugiere madurez competitiva en los juveniles.
 - **Balance:** El promedio de goles como **local (1.66)** es ligeramente superior al de **visitante (1.33)**.
 - **Consistencia:** El hecho de que el máximo de goles de visitante sea **4** (*frente a un máximo de 5 como local*) indica que los goleadores clave no se intimidan fuera de casa.
 - **Insight:** Hay un grupo con una mentalidad estable, que mantiene su efectividad independientemente del escenario.