



RIVER PLATE

IURP
INSTITUTO UNIVERSITARIO
RIVER PLATE



UCAM
UNIVERSIDAD
CATÓLICA DE MURCIA

Módulo 07 – Memoria Final

Proyecto Integral

Ingeniería de datos Deportivo

Guillermo Román

Abril de 2026

Índice

I.	Introducción.....	3
	Contexto del proyecto	3
	Objetivos planteados	3
II.	Metodología.	4
	Fuentes de datos elegidas y justificación	4
	Proceso de extracción explicado	4
	Decisiones de diseño de base de datos.....	6
III.	Resultados.	7
	Principales hallazgos del análisis exploratorio.....	7
	Visualizaciones con interpretación	9
IV.	Desafíos y Soluciones.....	13
	Problemas encontrados	13
	Cómo se resolvieron.....	13
	Aprendizajes técnicos	13
V.	Conclusiones.	14
	Resumen de lo logrado	14
	Aplicabilidad en contextos reales	14
	Posibles mejoras futuras	14
VI.	Referencias y Recursos.....	15
	Fundamentos de Analítica Deportiva y Visualizaciones.....	15
	Ingeniería de Datos y Bases de Datos	15
	Herramientas Digitales	15

I. Introducción.

Contexto del proyecto

En el fútbol formativo moderno, la diferencia entre el estancamiento y la promoción de un talento reside en la capacidad de medir su evolución de manera objetiva. **La Academia M.F.C**, tras finalizar la “*Liga Promesas*” del *Municipio Caroní, Categoría Sub15, Torneo Apertura 2025*, se encontró ante un desafío común: *la infoxicación*. El SISTEMA COMET provee datos, pero residen en silos aislados: archivos CSV con estadísticas generales y actas en archivo PDF con el detalle técnico de cada encuentro. Para el caso particular de conocer el desempeño de los jugadores de cara al arco rival (por ejemplo, los goleadores del torneo), el COMET no provee directamente dicha estadística, por lo que tiene que revisarse manualmente las planillas PDF de los partidos, lo que no permite tomar decisiones informadas de forma expedita.

Este proyecto nace de la necesidad de la Dirección Deportiva de la Academia M.F.C, de contar no solo con una base de datos; sino de un sistema que permita transformar actas arbitrales estáticas en inteligencia deportiva, para así tomar de decisiones sobre promociones de categoría y detección de perfiles específicos.

Objetivos planteados

- **Centralización:** Unificar el flujo de datos proveniente de CSV (administrativo/competitivo) y PDF (técnico/táctico).
- **Ingeniería de Calidad:** Implementar procesos de limpieza (*Data Cleansing*) para estandarizar nombres de jugadores y equipos.
- **Escalabilidad:** Diseñar una estructura en MySQL capaz almacenar los datos necesarios y de crecer con cada torneo sucesivo.
- **Visualización de Insights:** Generación de gráficas que permitan entender rápidamente métricas claves del contexto formativo.

II. Metodología.

Fuentes de datos elegidas y justificación

- **Archivos CSV (generados por COMET):** Contiene la *estructura macro* de los torneos federados: calendarios, jornadas y resultados globales. Su facilidad de procesamiento los hace ideales para ser la base de toda la data.

```
datos > raw > Resultados_TA25_GrupoB_raw.csv > data
1  Jornada,Fecha/hora,Estadio,Partido,Resultado,Estado
2  1,12.04.2025 09:30,LICEO LOS OLIVOS,ACADEMIA M.f.c - CORE SPORT,0:4,JUGADO
3  1,10.04.2025 15:30,,ACADEMIA DEPORTIVA EMANUEL - ESCUELA DE FUTBOL MGD,3:3,JUGADO
4  1,11.04.2025 16:00,"LOS OLIVOS" PTO. ORDAZ,LOS OLIVOS - ACADEMIA SUR AEROPUERTO fc,0:5,JUGADO
5  2,21.03.2025 15:00,CANCHA VILLA BETANIA,S LUGO fc - ACADEMIA M.f.c,1:2,JUGADO
6  2,22.03.2025 14:00,CANCHA EL CAMPITO-CORE 8,CORE SPORT - ACADEMIA DEPORTIVA EMANUEL,3:0*,JUGADO
7  2,21.03.2025 15:45,"""CIUDAD MINEROS"" PTO. ORDAZ",ESCUELA DE FUTBOL MGD - LOS OLIVOS,3:0*,JUGADO
8  3,25.03.2025 16:30,LICEO LOS OLIVOS,ACADEMIA M.f.c - ACADEMIA DEPORTIVA EMANUEL,4:2,JUGADO
9  3,22.03.2025 10:00,CANCHA UNION UNARE,ACADEMIA SUR AEROPUERTO fc - ESCUELA DE FUTBOL MGD,1:0,JUGADO
10 3,23.03.2025 09:00,CANCHA EL CAMPITO-CORE 8,CORE SPORT - S LUGO fc,4:3,JUGADO
11 4,29.03.2025 14:30,CANCHA UNION UNARE,ACADEMIA SUR AEROPUERTO fc - ACADEMIA M.f.c,3:0,JUGADO
12 4,29.03.2025 16:00,PARATEPUY,ACADEMIA DEPORTIVA EMANUEL - S LUGO fc,1:3,JUGADO
```

- **Planillas PDF (Informes de Partido generados por COMET):** La fuente más rica y compleja. Contienen la data de lo ocurrido en cada jornada del torneo: Datos Básicos (Liga, categoría, grupo, equipos, fecha, hora, ubicación, oficiales, plantillas, cuerpos técnicos) e Incidencias (sustituciones, goles jugada, penales o autogoles, amonestaciones y expulsiones).

COMET - Federación Venezolana de Fútbol

Fecha: 25.03.2026 Hora: 21:39:34 VET Impreso por: Alid villareal (178732977)

LIGA PROMESAS FÚTBOL CAMPO MUN CARONÍ SUB-15 2025
TA 2025 - GRUPO B
ACADEMIA M.F.C vs LOS OLIVOS
5:1 (2:1)

Publico: INFORME DE PARTIDO

Fecha: 10/06/2025 Hora: 16:00 Estadio: 37

OFICIALES DE PARTIDO									
Árbitro: Brito, Omar									
Equipo A ACADEMIA M.F.C (Venezuela)					Equipo B LOS OLIVOS (Venezuela)				
Jugadores					Jugadores				
Nº	Apellido	Nombre	T/S	A/C	Nº	Apellido	Nombre	T/S	A/C
1	99	Rosales Gomez	Moises Sebastian	T A	6	Fuenmayor Freitas	Sebastian Ali	T A	1
2	5	Maita Salas	Jeremias Jatniel	T C	3	Paez Romero	Jesus Abraham	T	2
3	7	Adedigba Zapata	Emmanuel Aderemi Oluwaseun	T	8	Chapellin Padron	Adrian Augusto	T	3
4	8	Rincones Ruiz	Guillermo Alexander	T	9	Peñaranda Gil	Joshua Mathias	T	4
5	11	Sanchez Rada	Emmanuel Abraham	T	11	Rojas Delgado	Francisco Jose	T	5
6	18	Diaz Villegas	Samuel Alejandro	T	13	Benitez Castillo	Emanuel Said	T	6
7	40	Daza Beliz	Daza Beliz	T	14	Mora Barreto	Jose Francisco	T C	7

Proceso de extracción explicado

El corazón técnico del proyecto reside en funciones desarrolladas en Python, para la extracción de textos crudos y almacenamiento de estos en Listas y Diccionarios, que luego fueron transformados en DataFrames, para poder ser manipulados. Dependiendo del tipo de fuente de datos, los archivos crudos se procesaron de una forma en particular:

- **Archivos .CSV:** Por ser archivos de tipo estructurados, el texto se extrajo utilizando la librería “Pandas”, con su función Read.CSV.

```
#Carga de Archivo CSV con resultados de la Liga Promesas Caroní - Sub15 - Torneo Apertura 2025 - Grupo B.
df_Resultados_TA25_GrupoB = pd.read_csv("../datos/raw/Resultados_TA25_GrupoB_raw.csv")

#Se verifica que el dataset se haya cargado correctamente, mostrando su forma (número de filas y columnas).
print("Datasets cargados correctamente:")
print(f"Resultados - Liga Promesas, Mun. Caroní - Sub15 - TA2025 - Grupo B, tiene: {df_Resultados_TA25_GrupoB.shape[0]}")

Python

Datasets cargados correctamente:
Resultados - Liga Promesas, Mun. Caroní - Sub15 - TA2025 - Grupo B, tiene: 42 filas x 6 columnas
```

- **Archivos .PDF:** Debido a que son archivos de tipo semiestructurados, la metodología de extracción del texto fue más compleja, se utilizó la librería “pdfplumber”, ya que tiene funciones para facilitar la extracción del texto crudo de cada página del Informe de Partido del COMET, donde la primera página contiene los datos básicos del encuentro, y la segunda página contiene las incidencias. Finalmente, para que el texto crudo tuviera sentido, se dividió el proceso en fases:

- **Detección de Patrones (Regex):** Implementación de expresiones regulares para capturar patrones de nombres, dorsales y números.

```
#Capturar la liga
match_liga = re.search(r'LIGA\s+(.*?)\s+FÚTBOL CAMPO', texto)
if match_liga:
    resultado['liga'] = match_liga.group(1)

# Patrón de descubrimiento: (Numero Lista) (Dorsal) (Nombre) (T/S) (A/C opcional)
patron_descubrimiento = r"(\d+)\s+(\d+)?\s+([A-Za-zÑÑáéíóúÁÉÍÓÚ]+\s+([TtSs]))(?:\s+([AaCc][\d]*))?"
```

- **Anclaje Geográfico:** Uso de coordenadas para seccionar las páginas del Informe COMET en dos "cajas": *Local* y *Visitante*, y así extraer correctamente el texto deseado.

```
ancho_mitad = pag_goles.width / 2
cajas = {
    "LOCAL": (0, y_inicio, ancho_mitad, y_fin),
    "VISITANTE": (ancho_mitad, y_inicio, pag_goles.width, y_fin)
}
```

- **Normalización de Nombres:** Implementación de un algoritmo de limpieza, que elimina ruidos (como textos huérfanos o sin sentido) y reestructura nombres largos a un formato estándar de: 2 Apellidos y 2 Nombres.

```
# Filtramos para asegurar que solo recogemos letras (evitando basura numérica)
texto_antes = re.sub(r'^A-Za-zÑÑáéíóúÁÉÍÓÚ\s', '', texto_antes).strip()
texto_despues = re.sub(r'^A-Za-zÑÑáéíóúÁÉÍÓÚ\s', '', texto_despues).strip()

# Procesar el nombre (estricto: 4 palabras máximo)
nombre_completo = partes[2].split()
if len(nombre_completo) >= 4:
    nombre_final = " ".join(nombre_completo[:4])
else:
    continue # Se ignora por formato incompleto
```


Decisiones de diseño de base de datos

Se optó por un modelo relacional en MySQL, bajo un esquema de estrella simplificada con 3 *tablas principales*, para optimizar las consultas de rendimiento:

- **Tabla Jugadores (Dimensión):** Maestro con datos de los jugadores de categorías formativas. Almacenará los datos únicos de los protagonistas. Se alimenta del CSV de Goleadores.
- **Tabla Partidos (Dimensión):** Registro de encuentros, fechas y localía. Se alimenta del CSV de Resultados.
- **Tabla Eventos_Goles (Hechos):** Tabla que vincula al jugador con el minuto, el tipo de gol y la condición del partido. Se relaciona a las otras tablas mediante dos Llaves Foráneas (Foreign Key): *id_jugador* e *id_partido*. Se alimenta del CSV de Tabla General.

Relaciones:

- Un jugador puede anotar muchos goles (1:N).
- En un partido pueden ocurrir muchos eventos de gol (1:N).



III. Resultados.

Principales hallazgos del análisis exploratorio

El procesamiento del Torneo Apertura SUB-15 reveló que, a nivel general, hay mayor efectividad de las canteras cuando juegan como visitantes, donde fueron marcados **23 goles de visita** (vs 17 goles de local); por otro lado, **39 goles se marcan de Jugada y apenas 1 de Penal**, todo esto es indicativo de buen juego asociado por parte las academias formativas del municipio, y que no dependen de Penales, para poder ganar sus encuentros.

TABLA DE GOLEADORES SUB-15 DETALLADA - TORNEO APERTURA 2025 - GRUPO B								
	jugador	equipo	total_goles	goles_local	goles_visitante	jugada	penal	autogol
1	ADEDIGBA ZAPATA EMMANUEL ADEREMI	ACADEMIA M.F.C	7	5	2	7	0	0
2	GUTIERREZ BOLIVAR MATHIAS EDUARDO	ACADEMIA M.F.C	6	2	4	6	0	0
3	VALDEZ ROCA GABRIEL ALEXANDER	S LUGO FC	3	1	2	3	0	0
4	MARCANO ALCALA NELSON JAVIER	ACADEMIA M.F.C	2	0	2	2	0	0
5	GONZALEZ MARCANO GUILLERMO ALEJANDRO	ACADEMIA SUR AEROPUERTO FC	2	2	0	2	0	0
6	CAVADIA OCA LUIS MARIO	CORE SPORT	2	0	2	2	0	0
7	SEBASTIAN SHAMA HERNANDEZ SALAZAR	ESCUELA DE FUTBOL MGD	2	1	1	2	0	0
8	ROJAS MENDEZ CRISTIAN JESUS	CORE SPORT	2	0	2	2	0	0
9	BACA VELASQUEZ ANGEL EZEQUIEL	ACADEMIA SUR AEROPUERTO FC	1	1	0	1	0	0
10	AGUILERA REYES DAVID ENRIQUE	ESCUELA DE FUTBOL MGD	1	1	0	1	0	0
11	ESCALONA FARIAS ISAAC JAVIER	LOS OLIVOS	1	0	1	1	0	0
12	DIAZ VILLEGAS SAMUEL ALEJANDRO	ACADEMIA M.F.C	1	1	0	1	0	0
13	GUZMAN ORTIZ SAMUEL DAVID	ACADEMIA SUR AEROPUERTO FC	1	0	1	1	0	0
14	FIGUERA DIAZ MAYKOL JOSE	ACADEMIA DEPORTIVA EMANUEL	1	0	1	1	0	0
15	RAMIREZ ASCANIO FLAVIO MANUEL	ACADEMIA DEPORTIVA EMANUEL	1	0	1	1	0	0
16	MARCANO CAMACHO JUAN MARCOS	ACADEMIA M.F.C	1	1	0	0	1	0
17	MAESTRE RODRIGUEZ JOSE MANUEL	S LUGO FC	1	0	1	1	0	0
18	RINCONI FLORES EMMANUEL JOSE	ESCUELA DE FUTBOL MGD	1	0	1	1	0	0
19	RINCONES RUIZ GUILLERMO ALEXANDER	ACADEMIA M.F.C	1	1	0	1	0	0
20	SOLARTE REINA LUIS ANTONIO	CORE SPORT	1	1	0	1	0	0
21	YANEZ SUAREZ ROGER JAVIER	S LUGO FC	1	0	1	1	0	0
22	ZURITA ROBLES JESUS ANDRES	ESCUELA DE FUTBOL MGD	1	0	1	1	0	0
23	TOTALES	-	40	17	23	39	1	0

Una vez filtrados los datos, para tener solo la información asociada a la **Academia M.F.C**, se reveló que la efectividad de la cantera no es lineal. Se detectó, por ejemplo, que un goleador mantiene una cuota alta cuando juega de local, pero su participación decae en contextos de visitante, y con otros goleadores ocurre exactamente lo contrario, lo que sugiere una *oportunidad de intervención táctica o de acompañamiento psicológico*.

DESEMPEÑO INDIVIDUAL: GOLEADORES SUB-15 CANTERA ACADEMIA MFC - TORNEO APERTURA 2025 - GRUPO B								
	jugador	equipo	total_goles	goles_local	goles_visitante	jugada	penal	autogol
1	ADEDIGBA ZAPATA EMMANUEL ADEREMI	ACADEMIA M.F.C	7	5	2	7	0	0
2	GUTIERREZ BOLIVAR MATHIAS EDUARDO	ACADEMIA M.F.C	6	2	4	6	0	0
3	MARCANO ALCALA NELSON JAVIER	ACADEMIA M.F.C	2	0	2	2	0	0
4	DIAZ VILLEGAS SAMUEL ALEJANDRO	ACADEMIA M.F.C	1	1	0	1	0	0
5	MARCANO CAMACHO JUAN MARCOS	ACADEMIA M.F.C	1	1	0	0	1	0
6	RINCONES RUIZ GUILLERMO ALEXANDER	ACADEMIA M.F.C	1	1	0	1	0	0
7	TOTAL CANTERA MFC	ACADEMIA M.F.C	18	10	8	17	1	0

Observando las estadísticas descriptivas, con la función `.describe()`, se pueden extraer hallazgos muy valiosos. Las cifras cuentan la historia de un equipo que tiene una jerarquía ofensiva muy marcada y una identidad de juego clara.

```
--- Estadísticas Descriptivas del DataFrame de GOLEADORES SUB-15 - CANTERA ACADEMIA MFC
```

	total_goles	goles_local	goles_visitante	jugada	penal	autogol
count	6.00000	6.000000	6.000000	6.000000	6.000000	6.0
mean	3.00000	1.666667	1.333333	2.833333	0.166667	0.0
std	2.75681	1.751190	1.632993	2.926887	0.408248	0.0
min	1.00000	0.000000	0.000000	0.000000	0.000000	0.0
25%	1.00000	1.000000	0.000000	1.000000	0.000000	0.0
50%	1.50000	1.000000	1.000000	1.500000	0.000000	0.0
75%	5.00000	1.750000	2.000000	5.000000	0.000000	0.0
max	7.00000	5.000000	4.000000	7.000000	1.000000	0.0


Observaciones:

- **Polarización.** Existe una brecha significativa entre la producción promedio y los líderes de goleo.
 - **Volumen:** Hay un universo de **6 goleadores** registrados en el periodo.
 - **Desigualdad:** Mientras que la **mediana (50%)** es de apenas **1.5 goles**, el valor **máximo es de 7**. Esto indica que el peso ofensivo recae fuertemente en 1 o 2 jugadores (Enmanuel Adedigba y Mathías Gutiérrez).
 - **Insight Clave:** El equipo es altamente dependiente de sus finalizadores principales. Si el rival logra anular al jugador con el récord de 7 goles, la probabilidad de anotar cae drásticamente.
- **ADN de Juego: Goles de Jugada.** El equipo no depende de autogoles del rival, ni de balones detenidos para marcar.
 - **Dominio de Jugada:** El promedio de goles de jugada (**2.83**) es casi idéntico al promedio de goles totales (**3.0**).
 - **Penales:** La incidencia es mínima (*media de 0.16*), con un máximo de solo **1 gol de penal** entre todos los jugadores.
 - **Insight Clave:** Esto habla muy bien del proceso formativo y la capacidad asociativa de la Sub-15. El equipo genera sus propias ocasiones a través del sistema táctico, lo cual es ideal en etapas de desarrollo.
- **Factor de Localía vs. Visitante.** El rendimiento es equilibrado, lo que sugiere madurez competitiva en los juveniles.
 - **Balance:** El promedio de goles como **local (1.66)** es ligeramente superior al de **visitante (1.33)**.
 - **Consistencia:** El hecho de que el máximo de goles de visitante sea **4** (*frente a un máximo de 5 como local*) indica que los goleadores clave no se intimidan fuera de casa.
 - **Insight Clave:** Hay un grupo con una mentalidad estable, que mantiene su efectividad independientemente del escenario.

Visualizaciones con interpretación

Distribución de Variables: Minutos de Anotación (Física y Concentración).

Usando los datos de todos los goles marcados durante el torneo, el siguiente gráfico permite entender en qué momento del partido ocurren las anotaciones, lo que es vital en categorías juveniles, donde la resistencia física y la concentración fluctúan más, que en el fútbol profesional.




Interpretación Estratégica.

- **El "Efecto Vestuario" (Minutos 5' al 10').** Se observa un pico pronunciado de goles en los primeros minutos del encuentro. Esto indica que el torneo tiene un inicio muy intenso o defensas que entran "frías". Se nota una falta de concentración inicial generalizada en el Grupo B.
Acción Estratégica: Revisar los protocolos de calentamiento y concentración de la Academia.
- **La "Meseta de Confort" (Minutos 20' al 40').** Hay una caída notable en la frecuencia de goles durante la parte media del primer tiempo. Esto indica que una vez pasado el ímpetu inicial, los partidos entran en una fase de estudio o de equilibrio táctico donde las defensas se asientan.
Acción Estratégica: Este es el momento ideal para realizar variantes tácticas desde el banquillo, para romper el orden del rival, ya que el ritmo de juego baja y el control aumenta.
- **El "Retorno de los Goles". (Minutos 40' al 45').** El efecto del cansancio de los últimos minutos del 1er tiempo se hace evidente y vuelven a aumentar la frecuencia de los goles anotados.
Acción Estratégica: Realizar indicaciones desde el banquillo, para mantener el orden y control del balón, ya que perderlo es sinónimo de gol encajado.
- **Resiliencia Post-Descanso (Minutos 45' al 60').** A diferencia del inicio del primer tiempo, el inicio del segundo tiempo es mucho más contenido. Esto indica que los ajustes realizados por los entrenadores en el entretiempo están surtiendo efecto defensivo inmediato.
- **El Factor Crítico: El Cierre del Partido (Minutos 70' en adelante').** El gráfico muestra su punto más alto de letalidad en el último cuarto del partido, especialmente alrededor del minuto 70. En el fútbol juvenil, este es el "minuto de la fatiga". La capacidad táctica para retroceder y cerrar espacios se desploma por cansancio físico.

Acción Estratégica: Gestión de Cargas. Los datos justifican que los cambios realizados al minuto 60-65 son los que realmente definen los partidos en este torneo.

Comparación entre Grupos: Rendimiento Ofensivo según Localía.

El siguiente gráfico proporciona una radiografía del carácter competitivo y la madurez de los goleadores de la **Academia MFC**. Al analizar la distribución de goles entre **Local** y **Visitante**, podemos extraer conclusiones tácticas y psicológicas fundamentales para el desarrollo de los juveniles.



Interpretación Estratégica.

- **El Factor "Mentalidad de Hierro": Mathias Gutiérrez.** A diferencia de la tendencia general, Mathías presenta un perfil sumamente interesante y atípico. Es el único jugador del club que anota *el doble como visitante (4) que como local (2)*.

Acción Estratégica: Este jugador es especial para partidos de alto riesgo fuera de casa. Su rendimiento crece en canchas ajenas.

- **El "Dominator de Casa": Emmanuel Adedigba.** Se confirma como el máximo referente, pero con un matiz de localía muy marcado. *Ha marcado 5 de sus 7 goles (71%) jugando de local.*


Acción Estratégica: Este jugador aprovecha el entorno de su propia cancha. Sin embargo, hay una oportunidad de mejora en su adaptación fuera de casa, para que sea un jugador fuera de lote.

- **La Brecha de "Acompañamiento".** Detrás de los dos líderes, el aporte goleador cae drásticamente. El equipo tiene una "Goleador-dependencia" fuera de casa, ya que casi todos los goles de visitante se concentran en solo tres nombres: Emmanuel Adedigba, Mathías Gutiérrez y Nelson Marcano.

Acción Estratégica: El cuerpo técnico debe trabajar en la llegada de la segunda línea. Si los rivales identifican que solo dos jugadores marcan fuera de casa, las marcas serán más férreas sobre ellos.

Relaciones entre Variables: Goles Local vs. Visitante.

Este gráfico actúa como un "mapa de calor" de la competitividad durante el **Torneo Apertura 2025**. A diferencia de los gráficos anteriores que se centraban en individuos, este nos da el contexto donde compete el equipo Sub-15 de la **Academia MFC**.



Interpretación de las Variables Relacionadas:

- **Eje X (Goles Local) vs. Eje Y (Goles Visitante):** Los puntos por **debajo de la línea roja** representan victorias locales. Los puntos por **encima de la línea roja** representan victorias visitantes. Si los puntos están muy dispersos y alejados del origen (0,0), el torneo es altamente ofensivo.
- **Color (Jornada):** Permite ver si el torneo se volvió más defensivo o cerrado conforme avanzaron las fechas (por ejemplo, si los colores más claros/oscuros se concentran cerca del 0:0).
- **Tamaño (Goles Totales):** Resalta visualmente los partidos donde se marcaron muchos goles, lo cual es un indicador de la falta de balance defensivo, en la categoría Sub-15.

Interpretación Estratégica:

- **El Torneo de la "Desigualdad Ofensiva":** La mayoría de los puntos están alejados de la línea diagonal punteada (la línea de empate). Esto quiere decir que muy pocos empates y que el torneo se caracteriza por victorias claras, muchas de ellas con marcadores abultados (puntos en las coordenadas 7:0 o 0:6). *Acción Estratégica:* En este grupo, el primer equipo en marcar tiene una ventaja psicológica enorme. Los partidos no se "*pelean*" en el marcador, sino que se "*rompen*". Trabajar la resiliencia tras recibir el primer gol, es crítico para la Academia MFC.
- **El Techo de los 3 Goles (Localía).** En el eje X (Goles Local), hay una barrera invisible: casi ningún equipo local logra pasar de los 3 goles, a excepción de casos muy aislados. En cambio, en el eje Y (Goles

Visitante), vemos puntos que llegan hasta el 5 y 6. En este torneo ser visitante no ha sido una desventaja defensiva para los equipos fuertes; de hecho, los visitantes han logrado goleadas más escandalosas que los locales.

Acción Estratégica: La Academia MFC debe perder el "respeto" excesivo al campo rival. Los datos muestran que las defensas locales en el Grupo B son vulnerables y permiten marcadores altos.

- **La Zona de "Seguridad Defensiva" (Cuadrante 0-1).** Hay una alta densidad de puntos en la zona de 0 y 1 gol visitante. Muchos equipos se quedan en "blanco" o anotan apenas un gol cuando salen de casa. Esto refuerza lo que vimos en el gráfico anterior de la Academia: marcar fuera de casa es el verdadero reto del torneo.

Acción Estratégica: Cualquier equipo que logre promediar 2 goles como visitante tiene una probabilidad estadística altísima de ganar casi todos sus partidos, dado que la mayoría de los locales no están pasando de 1 o 2 goles.

- **Relación Jornada vs. Goles (Tamaño de puntos)** Los puntos más grandes (partidos con más de 5 goles totales) parecen estar dispersos, pero hay una ligera tendencia a ver puntos más pequeños en jornadas avanzadas (colores amarillos/verdes claros). Esto sugiere que, conforme avanzó el torneo, los equipos ajustaron mejor sus defensas o el cansancio físico redujo el ritmo vertiginoso de las primeras fechas.

Acción Estratégica: Para otros torneos, la preparación debe ser máxima al inicio. Los equipos están más desordenados en las primeras 4 jornadas y es donde se pueden sacar las ventajas de puntos más grandes.

IV. Desafíos y Soluciones.

Problemas encontrados

- **Inconsistencia de Formato:** El mayor reto fue la variabilidad en los nombres dentro de los archivos PDF (ej. nombres invertidos, muy largos o abreviados).
- **Estructura de Páginas:** La información necesaria estaba fragmentada (Nombres de equipos en Pág. 1, Eventos en Pág. 2).
- **Ruptura de la Integridad Referencial:** Los archivos originales eran "planos" (hojas aisladas). No existía un identificador único que conectara un evento de gol con un partido específico, más allá de la coincidencia de nombres y fechas.
- **Complejidad en la Identificación de Contexto:** Determinar si un gol fue anotado en condición de local o visitante requería una lógica de cruce de datos entre el equipo del jugador y el rol del equipo en el partido.

Cómo se resolvieron

- **Pipeline de Limpieza con Pandas:** Se implementó una capa de transformación (ETL) en Python que utilizó expresiones regulares y funciones personalizadas para limpiar strings y convertir resultados de texto, a valores numéricos procesables por la base de datos.
- **Lógica Deductiva de Nombres:** Se implementó un sistema de "wrap-up/wrap-down" en el procesamiento de texto para capturar nombres que se desbordaban en múltiples líneas, asegurando que ningún dato quedara fuera del registro.
- **Normalización y Modelado Relacional:** Se migró de un modelo de "tabla única" a un *Esquema en Estrella* en MySQL. Se crearon tablas de dimensiones (jugadores, partidos) y una tabla de hechos (eventos_goles) vinculadas mediante Llaves Foráneas (FK).
- **Lookups Dinámicos:** Durante la carga de goles, el script de Python realiza búsquedas dinámicas en la base de datos para encontrar el "*id_partido*" correspondiente, comparando la fecha del evento y el equipo involucrado, asegurando una trazabilidad total.

Aprendizajes técnicos

- **Importancia de la Calidad del Dato (Data Quality):** El análisis visual (Scatter Plots, gráficos de barras) es tan bueno como la limpieza previa. Un solo dato mal formateado (como un 3:0*) puede romper un pipeline completo de analítica.
- **Storytelling con Datos:** Se aprendió a seleccionar la variable correcta para cada visualización. El Scatter Plot resultó ser la mejor herramienta para entender el equilibrio competitivo de la liga, mientras que los gráficos de barras segmentados revelaron perfiles psicológicos de los jugadores (como la resiliencia de visitante).
- **Automatización de Reportes:** La capacidad de generar insights estratégicos de forma automática reduce el tiempo de respuesta del cuerpo técnico de días a segundos.

V. Conclusiones.

Resumen de lo logrado

La Academia MFC cuenta ahora con una base histórica digitalizada que servirá de cimiento para futuras temporadas. Se ha consolidado una infraestructura técnica robusta que abarca desde la captura hasta la explotación de datos:

- **Ingeniería de Ingesta:** Extracción y limpieza exitosa de fuentes diversas (PDF y CSV), normalizando métricas de goles y resultados.
- **Arquitectura de Datos:** Implementación de una base de datos **MySQL** bajo un modelo relacional (*cantera_db*), garantizando integridad referencial y eliminando la redundancia mediante una lógica de carga idempotente en Python.
- **Análítica Estratégica:** Identificación de patrones competitivos, como la vulnerabilidad defensiva en contextos específicos y la eficiencia de marcaje de goles en tramos críticos del partido, superando el análisis meramente descriptivo.

Aplicabilidad en contextos reales

Este proyecto no es solo un ejercicio académico; tiene una utilidad inmediata en el ecosistema deportivo:

- **Gestión de Talento:** Permite a los cuerpos técnicos identificar qué jugadores tienen mayor peso específico en los resultados (*goles clave*) para priorizar su desarrollo.
- **Servicios de Consultoría:** Establece un producto mínimo viable (MVP) para ofrecer servicios de digitalización y análisis a otras asociaciones o clubes, que utilicen el Sistema COMET. Permitiendo profesionalizar el área de metodología, sin incurrir en costos de software de scouting de élite, mediante el uso herramientas de código abierto.
- **Optimización Táctica:** Los entrenadores pueden ajustar sus planes de partido basándose en datos objetivos sobre el rendimiento de los rivales en diferentes canchas.

Posibles mejoras futuras

El sistema está diseñado para ser la base de una plataforma mucho más ambiciosa:

- **Integración IoT/GNSS:** El siguiente paso lógico es vincular la tabla de “*eventos_goles*” con datos de sensores para analizar la carga física (distancia, sprints, etc) que precede a un gol.
- **Automatización de Video (Computer Vision):** Integrar clips de video automáticos vinculados a cada “*id_evento*” en la base de datos para facilitar el video-análisis.
- **Dashboard en Tiempo Real:** Migrar las visualizaciones estáticas a un tablero dinámico en Power BI o Streamlit, conectado directamente a la base de datos MySQL.

VI. Referencias y Recursos.

Fundamentos de Analítica Deportiva y Visualizaciones

Estos textos validan por qué el análisis deportivo y la ciencia de datos son críticos en el fútbol moderno.

- **Anderson, C., & Sally, D. (2013).** *The Numbers Game: Why Everything You Know About Soccer Is Wrong*. Penguin Books. Referencia clave sobre la importancia de los goles y la aleatoriedad en el fútbol.
- **Martin, L (2016).** *Sports Performance Measurement and Analytics*. Pearson Education, Inc. Este libro combina la medición deportiva con el análisis estadístico, demostrando cómo examinar las diferencias entre deportes y entre las posiciones de los jugadores.
- **McKinney, W. (2022).** *Python for Data Analysis*. O'Reilly Media. Referencia técnica para el uso de la librería **Pandas** en el procesamiento de datos.
- **Wilke, C (2019).** *Fundamentals of Data Visualization*. O'Reilly Media. Referencia técnica para crear visualizaciones que reflejen con precisión los datos, cuenten una historia y tengan un aspecto profesional.
- **Barça Innovation Hub (BIHUB):** Sus recursos sobre *Tactical Analysis* y *Sports Data* son referencia mundial en metodologías de entrenamiento y analítica deportiva.

Ingeniería de Datos y Bases de Datos

Para respaldar la manipulación de archivos en un modelo de datos relacionales:

- **Silberschatz, A., Korth, H. F., & Sudarshan, S. (2019).** *Database System Concepts*. McGraw-Hill. Es el estándar para explicar modelos relacionales y llaves foráneas.
- **Kimball, R., & Ross, M. (2013).** *The Data Warehouse Toolkit*. Wiley. Profundiza sobre técnicas de modelado de datos.
- **Tanimura, C. (2021).** *SQL for Data Analysis*. Wiley. Este libro práctico muestra técnicas avanzadas para mejorar habilidades, resolver problemas y sacar el máximo provecho de SQL.

Herramientas Digitales

Referencia sobre el Stack Tecnológico utilizado en el proyecto:

- **Python Software Foundation:** python.org
- **MySQL Community Server:** dev.mysql.com